Invătare Supervizată - Proiect

Etapa 2

Tarău Alexandru-Bogdan

344C1

Ian 2025

Contents

1 Cerința 1 - K-fold Cross-Validation **2**
1.1 Rezultate . . . 2
1.2 Concluzii . . . 2

2 Cerința 2 **3**
2.1 Rezultate . . . 3
2.2 Concluzii . . . 3

3 Cerința 3 **3**
3.1 Definirea seturilor de augmentări . . . 3
3.2 Rezultate . . . 4
3.3 Concluzii . . . 5

4 Cerința 4 **5**
4.1 Rezultate . . . 5
4.2 Concluzii . . . 6

5 Cerința 5 **6**
5.1 Configurația Modelului Baseline . . . 6
5.2 Ablation Study . . . 7

6 Bonus 1 **9**
6.1 Analiza Clasei: Epidural . . . 9
6.2 Analiza Clasei: Intraparenchymal . . . 9
6.3 Analiza Clasei: Intraventricular . . . 10
6.4 Analiza Clasei: Subdural . . . 10
6.5 Analiza Clasei: Subarachnoid . . . 11
6.6 Analiza Clasei: Any . . . 11

7 Bonus 2 **11**
7.1 Rezultate . . . 11
7.2 Concluzii . . . 12

Abstract

Abordez sarcina de a clasifica hemoragiile cerebrale din imagini CT. Construiesc și compar mai multe metode de preprocesare și clasificare, urmărind obținerea unui model robust care să depășească abordările tradiționale.

1 Cerința 1 - K-fold Cross-Validation

1.1 Rezultate

Fold	Validation				Test			
	Accuracy	Precision	Recall	F1-score	Accuracy	Precision	Recall	F1-score
1	0.6624	0.7490	0.3710	0.4736	0.2288	0.7065	0.3809	0.4753
2	0.6621	0.7170	0.4355	0.5306	0.2490	0.6839	0.4314	0.5120
3	0.6551	0.6936	0.4764	0.5514	0.2653	0.6758	0.4877	0.5466
4	0.6143	0.6604	0.5216	0.5750	0.2550	0.6612	0.5275	0.5587
5	0.6306	0.6600	0.5119	0.5493	0.2760	0.6631	0.5214	0.5684

Table 1: Performanța fiecărui fold ($k = 5$) pe seturile de Validare și Testare.

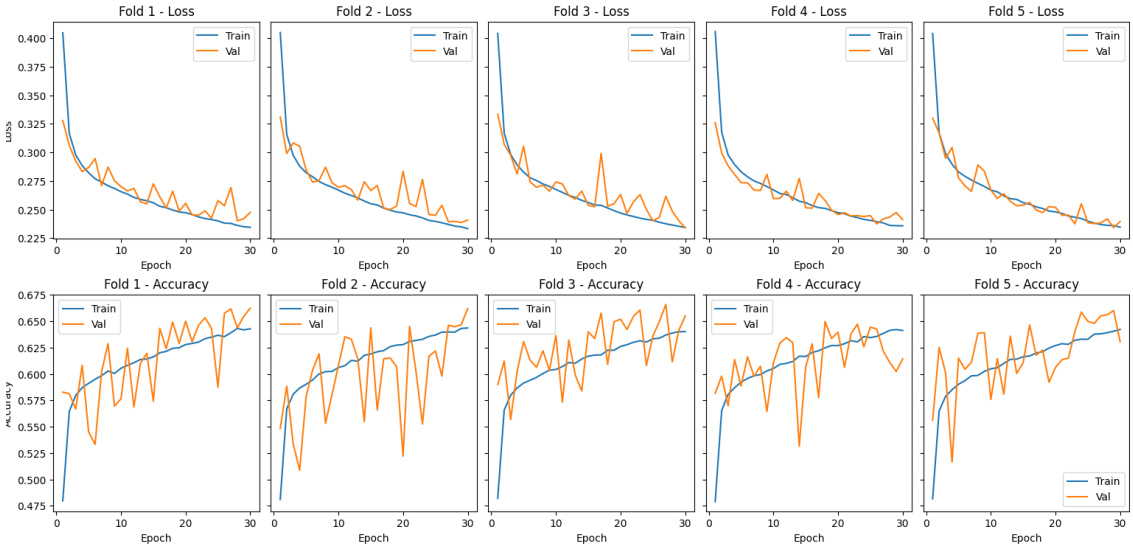

Figure 1: Evoluția pierderii (loss) și a acurateței (accuracy) pentru fiecare dintre cele 5 fold-uri.

Metrică	Validation (Media ± Std)	Test (Media ± Std)
Accuracy	0.6449 ± 0.0192	0.2548 ± 0.0159
Precision	0.6960 ± 0.0341	0.6781 ± 0.0165
Recall	0.4633 ± 0.0552	0.4698 ± 0.0560
F1-score	0.5360 ± 0.0342	0.5322 ± 0.0343

Table 2: Rezumatul performanței: media și deviația standard pe cele 5 fold-uri.

1.2 Concluzii

- **Stabilitatea Modelului**
  Deviația standard scăzută pentru metricile de testare (de exemplu, 0.0165 pentru Precision și 0.0159 pentru Accuracy) demonstrează că modelul este stabil. Performanța nu fluctuează drastic în funcție de eșantionarea

datelor, ceea ce confirmă faptul că arhitectura a învățat trăsături robuste, nu doar particularități ale unui anumit subset.

- **Analiza Metricilor și Generalizarea** Se observă o consistență remarcabilă a scorului F1 între validare (0.5360) și testare (0.5322), ceea ce confirmă o bună capacitate de generalizare a modelului. Deși acuratețea pe setul de testare este mai scăzută, menținerea valorilor de Precision ($\approx 68\%$) și Recall ($\approx 47\%$) pe date noi demonstrează că modelul păstrează un echilibru stabil și gestionează eficient clasificarea, în ciuda dezechilibrelor din setul de date.

2 Cerința 2

2.1 Rezultate

Metodă	Accuracy	Precision	Recall	F1-score
Fără balansare (Baseline)	0.2548	0.6781	0.4698	0.5322
Loss Weights	0.1179	0.5038	**0.8554**	**0.5868**
Oversampling (Simplu)	0.2429	0.6882	0.4727	0.4986
Oversampling (Augmentat)	0.2378	0.6881	0.4525	0.4875

Table 3: Comparație între metodele de balansare a claselor (Media pe setul de Test)

2.2 Concluzii

- **Impactul Loss Weights**
  Această metodă a produs cele mai drastice schimbări. Deși Accuracy a scăzut semnificativ (11.79%), am obținut cel mai mare Recall (85.54%) și cel mai bun F1-Score (0.5868). Acest lucru indică faptul că modelul a încetat să mai ignore clasele minoritare, devenind mult mai capabil să le identifice, chiar cu prețul unor rezultate fals pozitive suplimentare.

- **Oversampling vs. Baseline**
  Atât varianta simplă, cât și cea cu augmentări, au menținut o acuratețe și o precizie similare cu modelul de bază. Totuși, se observă că Oversampling-ul simplu a performat ușor mai bine decât cel augmentat în ceea ce privește F1-Score (0.4986 vs 0.4875).

- **Augmentarea Datelor**
  Tehnicile de augmentare aplicate (Rotație 30°, Flip, Color Jitter) nu au adus o îmbunătățire imediată în metrici față de simpla duplicare. Acest lucru sugerează că diversitatea vizuală introdusă nu a fost factorul critic în balansarea învățării pentru acest set specific de date, sau ar putea necesita un număr mai mare de epoci pentru a fi exploatată.

3 Cerința 3

3.1 Definirea seturilor de augmentări

- Set 1: Rotații, zoom și ajustări de intensitate (contrast, zgomot Gaussian).
- Set 2: Deformări elastice (Rand2DElastic), alături de rotații.
- Set 3: Deformări elastice, rotații, flip-uri, zoom și transformări de intensitate (blurare, contrast, zgomot).

3.2 Rezultate

Configurație	Accuracy	Precision	Recall	F1-Score	AUC (Test)
Set 1	0.2352	0.6413	0.5096	0.5464	0.8100
Set 2	**0.2546**	0.6503	**0.5591**	**0.5757**	**0.8267**
Set 3	0.2247	**0.6634**	0.4261	0.4945	0.8003

Table 4: Comparația performanței pe setul de testare pentru cele trei seturi de augmentări.

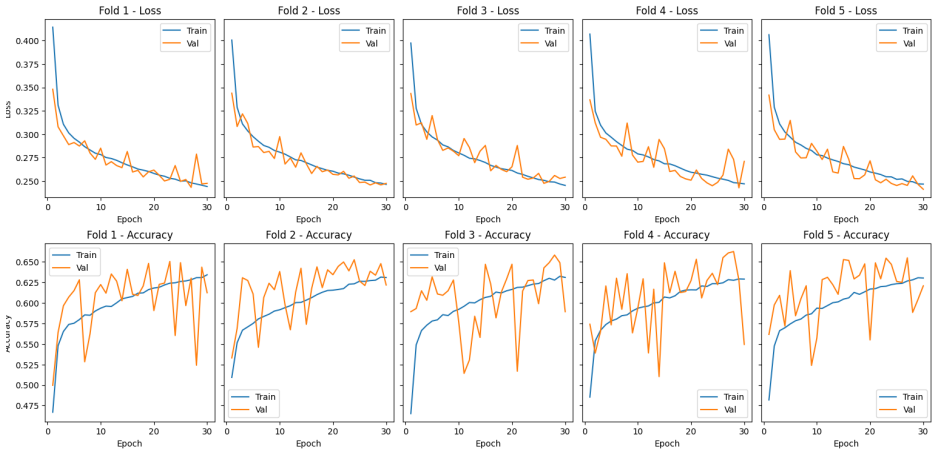

Figure 2: Evoluția Loss-ului și Accuracy pentru Setul 1.

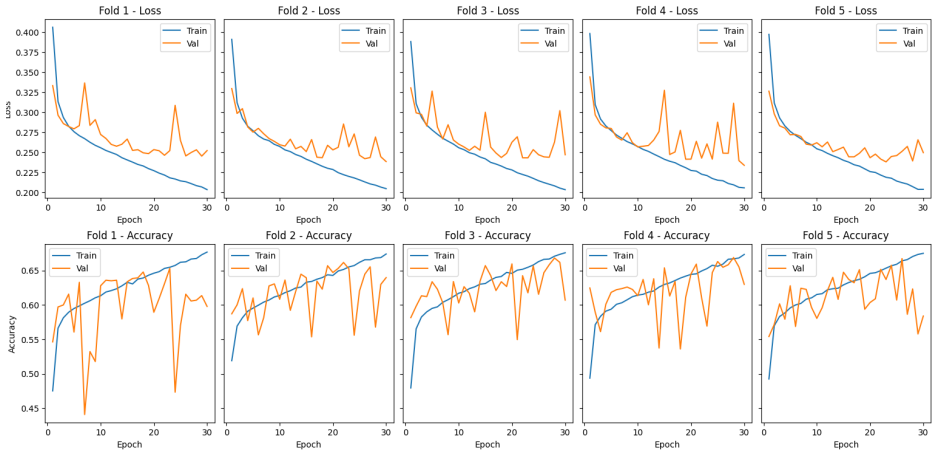

Figure 3: Evoluția Loss-ului și Accuracy pentru Setul 2.

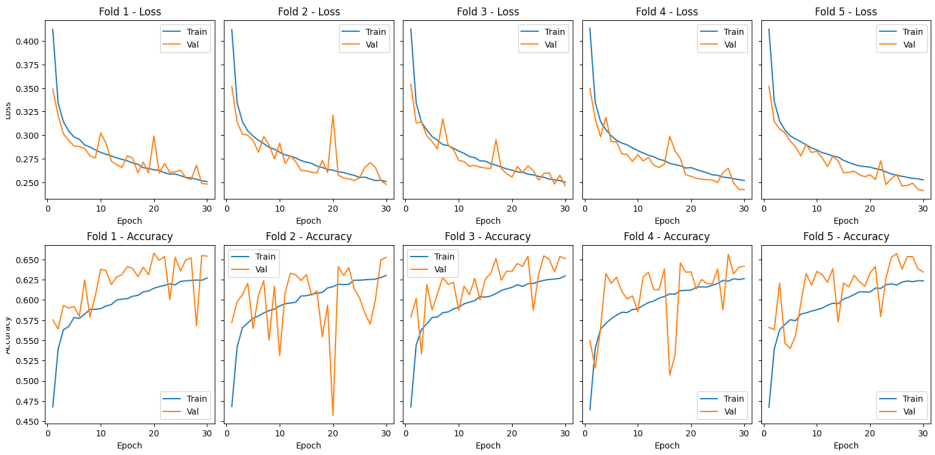

Figure 4: Evoluția Loss-ului și Accuracy pentru Setul 3.

3.3 Concluzii

- **Eficiența Deformării Elastice**
  Succesul Setului 2 se datorează utilizării Rand2DElastic. Aceasta întinde și modelează imaginile în moduri diferite, simulând variațiile naturale ale formelor organice. Deși Setul 2 a oferit cele mai bune rezultate pe setul de testare, analiza graficelor de pierdere (loss) indică un fenomen de overfitting.

- **Problema cu prea multe modificări (Setul 3)**
  Deși Setul 3 a avut cele mai multe tipuri de modificări, acesta a obținut cele mai slabe rezultate. Imaginile au fost modificate atât de mult (zgomot, blur, deformare și rotire simultan), încât au devenit nerealiste. Modelul a fost derutat de aceste distorsiuni excesive și nu a mai putut învăța trăsăturile importante care apar în realitate.

- **Echilibrul Setului 1**
  Acesta a oferit rezultate bune, confirmând că rotația și zoom-ul sunt utile, dar nu la fel de eficiente ca deformările elastice pentru acest tip de date medicale.

4 Cerința 4

4.1 Rezultate

Table 5: Compararea tehnicilor de optimizare pentru Fold 1 (cel mai slab fold baseline)

Metodă	Accuracy	Precision	Recall	F1-Score	AUC	Timp (s)
Early Stopping	0.1965	**0.7152**	0.3380	0.4142	0.7948	**1411.17**
Scheduler (LR)	**0.2531**	0.6833	**0.4666**	**0.5343**	**0.8213**	1567.81

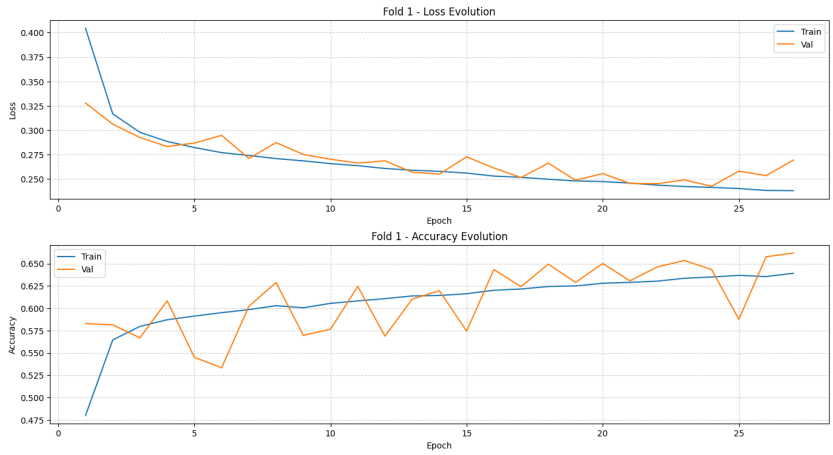

Figure 5: Evoluția Loss-ului și Accuracy pentru Early Stopping.

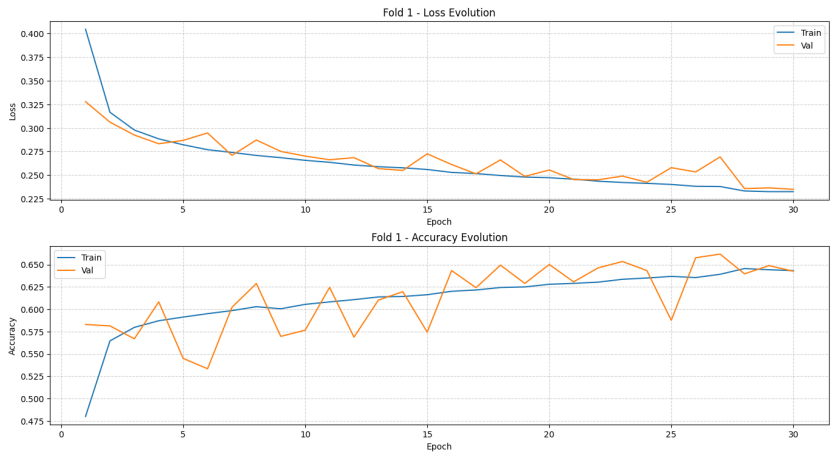

Figure 6: Evoluția Loss-ului și Accuracy pentru Loss Scheduling.

4.2 Concluzii

- **Precision vs. Recall**
  Este interesant de observat că Early Stopping a obținut o precizie mai mare (0.7152), dar un recall foarte scăzut (0.3380).

- **Echilibrul Scheduler-ului**
  Prin utilizarea ReduceLROnPlateau, am sacrificat puțină precizie pentru un câștig mare în Recall (de la 0.33 la 0.46). Acest lucru a dus la un F1-Score mult mai bun.

- **Compromisul Timp-Performanță**
  Deși Scheduler-ul a durat cu aproximativ 156 de secunde mai mult, îmbunătățirea în aproape toate categoriile de performanță justifică pe deplin timpul suplimentar de calcul.

5 Cerința 5

5.1 Configurația Modelului Baseline

Modelul propus utilizează arhitectura **EfficientNet-B0**, pre-antrenată pe setul de date ImageNet, adaptată pentru intrare monocanal și o ieșire multi-label de 6 clase.

Table 6: Hiperparametrii și Configurația de Antrenare

Componentă	**Valoare / Metodă**
Arhitectură	EfficientNet-B0
Funcție de pierdere	Focal Loss ($\alpha = 0.5, \gamma = 2.0$)
Optimizator	Adam ($lr = 1e-4, wd = 1e-4$)
Scheduler	ReduceLROnPlateau (Patience: 2, Factor: 0.1)
Early Stopping	Patience: 4 (Monitorizare Val Loss)
Batch Size	128
Prag de clasificare	0.42
Augmentări	Rotație ($\pm 30°$), Flip H/V, Color Jitter
Preprocesare	CLAHE, Sharpening, Normalizare
Post-procesare	Corecție consistență ierarhică

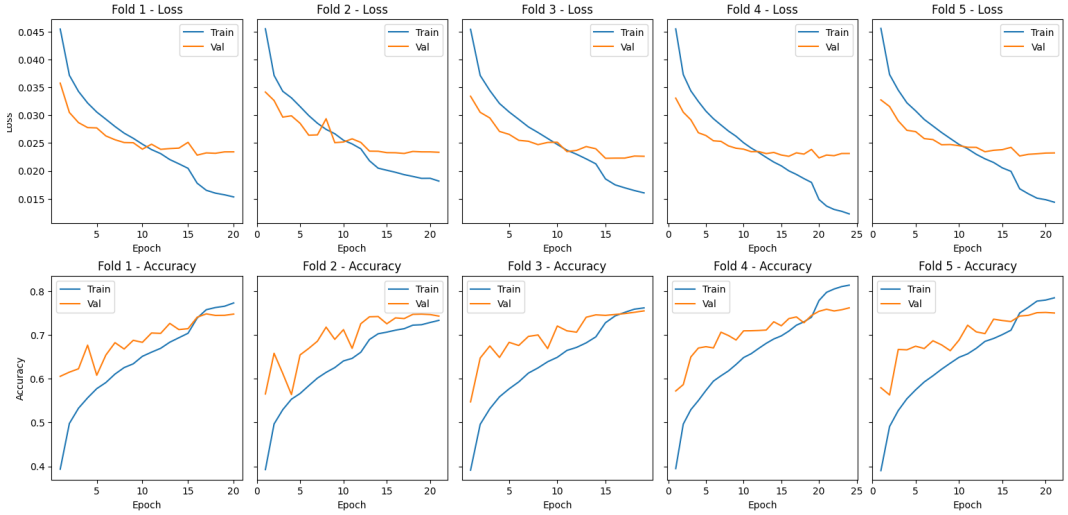

Figure 7: Evoluția Loss-ului și Accuracy pentru Modelul Baseline

Interpretarea curbelor de învățare: Analizând Figura 7, se observă următoarea evoluție: În primele epoci, performanța pe setul de validare este superioară celei de antrenament (Loss-ul de validare este mai mic), fenomen explicat prin utilizarea augmentărilor pentru a forța generalizarea. Totuși, spre finalul ciclului, performanța pe setul de antrenament continuă să se îmbunătățească, în timp ce curba de validare stagnează sau începe să descrească, indicând fenomenul de overfitting. Acest lucru sugerează că modelul a început să memoreze zgomotul din datele de antrenament, însă utilizarea mecanismului de *Early Stopping* a prevenit degradarea performanței pe setul de test.

5.2 Ablation Study

Studiul de ablație a fost efectuat pe Fold-ul 2, acesta fiind identificat ca având cele mai scăzute performanțe inițiale (Subset Accuracy: 45.05%, F1-Score: 0.7034). Am analizat impactul componentelor cheie prin experimente de modificare a funcției de pierdere, a optimizatorilor, a tehnicilor de augmentare și a echilibrării setului de date.

Configurație	**Accuracy**	**AUC**	**Precision**	**Recall**	**F1**	**Hamming**
Baseline (Adam + Over)	45.05%	0.9115	0.6922	0.7842	0.7034	0.7196
Ablation 1: BCE Loss	48.80%	0.9171	0.7332	0.7478	0.7157	0.7267
Ablation 2a: SGD	15.26%	0.6557	0.4639	0.5555	0.4918	0.4967
Ablation 2b: RMSprop	44.76%	0.9110	0.6939	0.7751	0.7010	0.7110
Ablation 3: No Aug.	41.10%	0.8966	0.6778	0.7644	0.6938	0.6919
Ablation 4: No Over.	47.19%	0.9158	0.7042	0.7915	0.7149	0.7325

Table 7: Metricele studiului de ablație (Fold 2)

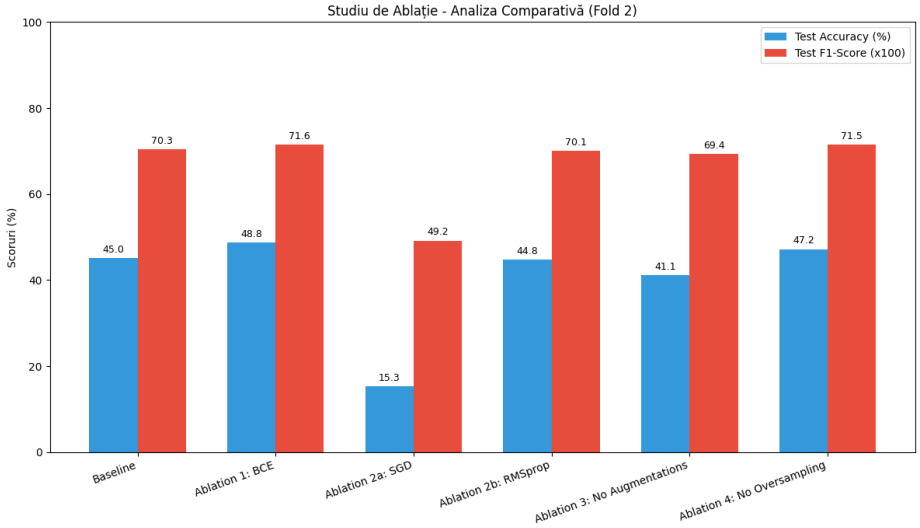

Figure 8: Comparația performanței între configurațiile de ablație

1. **Ablation 1**: BCE Loss în loc de Focal Loss

   - **Compararea versiunilor**
     Trecerea la BCE a dus la o creștere a Subset Accuracy la 48.80%. Aceasta sugerează că pentru acest subset de date, Focal Loss a fost poate prea agresiv în penalizarea erorilor, cauzând mici instabilități în gradient.
   - **Performanța pe clase minoritare**
     Deși acuratețea generală a crescut, s-a observat o scădere a **Recall-ului**. Focal Loss a forțat modelul să prioritizeze cazurile dificile (clasele minoritare), în timp ce BCE a favorizat o precizie mai mare pe cazurile majoritare (imagini fără hemoragie).

2. **Ablation 2**: Impactul Optimizatorilor (SGD și RMSprop)

   - **Impactul hiperparametrilor**
     Experimentul cu **SGD** a rezultat într-un colaps al performanței (15.26%), demonstrând că rețelele de tip EfficientNet depind critic de ratele de învățare adaptive. SGD ar fi necesitat un proces de tuning mult mai laborios pentru a ieși din minimele locale.
   - **Analiza RMSprop**
     Utilizarea **RMSprop** a oferit rezultate competitive (44.76% acuratețe), foarte apropiate de cele ale optimizatorului Adam din baseline.
   - **Concluzie optimizatori**
     În timp ce un algoritm rigid (SGD) s-a blocat și a eșuat, optimizatorii Adam și RMSprop s-au adaptat la complexitatea imaginilor medicale. Adam rămâne alegerea optimă, fiind cel mai stabil în gestionarea detaliilor fine.

3. **Ablation 3**: Eliminarea Augmentărilor

   - **Impactul regularizării (Overfitting)**
     Fără rotații și flip-uri, acuratețea a scăzut la 41.10%. Acest lucru confirmă faptul că modelul a început să memoreze orientările standard ale craniului din setul de antrenament în loc să învețe caracteristici anatomice generale.
   - **Concluzie augmentare:** Augmentările geometrice au funcționat ca o formă esențială de regularizare, asigurând robustețea modelului pe date de test provenite de la scanere diferite.

4. **Ablation 4**: Impactul Echilibrării Datelor (Fără Oversampling)

   - **Analiza rezultatelor**
     Eliminarea oversampling-ului a urcat puțin toate scorurile. Acest lucru se întâmplă, probabil, pentru

că modelul nu mai este distras de clasele rare și învață mult mai bine clasele majoritare, care domină statistic setul de date.

5. **Analiza Comparativă Finală**

   - **Echilibrul Precision-Recall**
     Modelul Baseline este cel mai echilibrat. Chiar dacă alte variante (BCE sau No Oversampling) au scos scoruri mai mari, ele au făcut-o ignorând cazurile dificile.
   - **Concluzie**
     Experimentele confirmă că succesul modelului nu vine dintr-o singură setare, ci din combinația celor trei: **Adam** pentru viteză, **Oversampling** pentru a nu ignora bolile rare și **Augmentări** pentru a nu învăța imaginile pe de rost.

6 Bonus 1

Am utilizat tehnica Grad-CAM pentru a vizualiza zonele de interes ale modelului. Mai jos sunt prezentate comparativ cazuri corecte și erori pentru clasele principale.

6.1 Analiza Clasei: Epidural

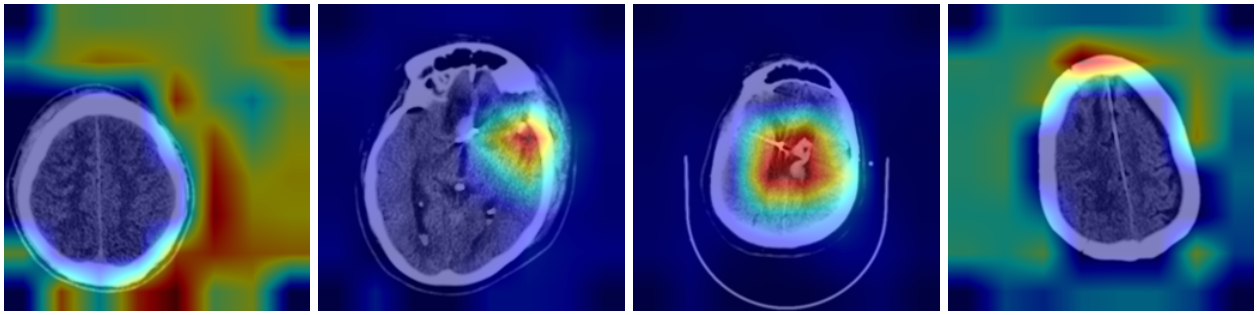

(a) Corect 0 (b) Corect 1 (c) Eroare 0 (d) Eroare 1

Figure 9: Vizualizări Grad-CAM pentru clasa Epidural.

Modelul pare să nu fi învățat că hemoragia epidurală trebuie să fie localizată strict la marginile craniului. Activările frecvente pe fundal (*background*) sugerează că succesul modelului este mai degrabă întâmplător sau bazat pe artefacte globale ale scanării.

6.2 Analiza Clasei: Intraparenchymal

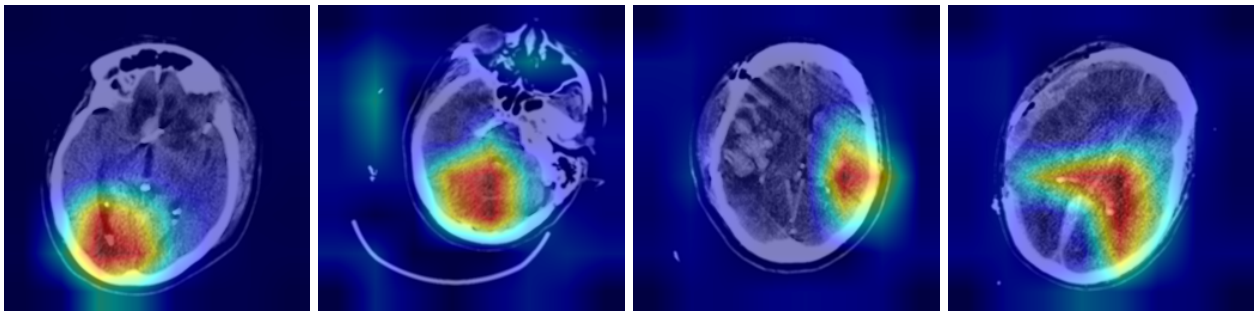

(a) Corect 0 (b) Corect 1 (c) Eroare 0 (d) Eroare 1

Figure 10: Vizualizări Grad-CAM pentru clasa Intraparenchymal.

Fiind o clasă mai frecventă în setul de date, se observă că modelul a învățat mai bine locația anatomică generală a hemoragiei față de alte clase. Totuși, analiza hărților de activare evidențiază faptul că modelul încă poate confunda această hemoragie cu alte tipuri (precum cea intraventriculară) din cauza proximității anatomice, sau poate rata complet identificarea leziunilor.

6.3 Analiza Clasei: Intraventricular

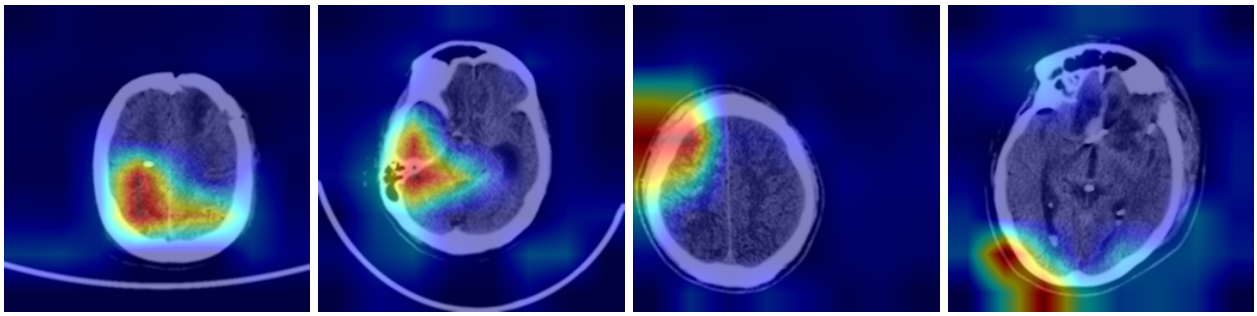

(a) Corect 0 (b) Corect 1 (c) Eroare 0 (d) Eroare 1

Figure 11: Vizualizări Grad-CAM pentru clasa Intraventricular.

Deși hemoragiile intraventriculare sunt localizate în centrul creierului, hărțile de activare arată că modelul tinde să se concentreze eronat spre zonele laterale sau spre fundal. Acest comportament indică faptul că modelul nu identifică sângerarea propriu-zisă din ventriculi, ci se bazează pe distrageri vizuale sau pe deformări indirecte ale creierului pentru a face predicția.

6.4 Analiza Clasei: Subdural

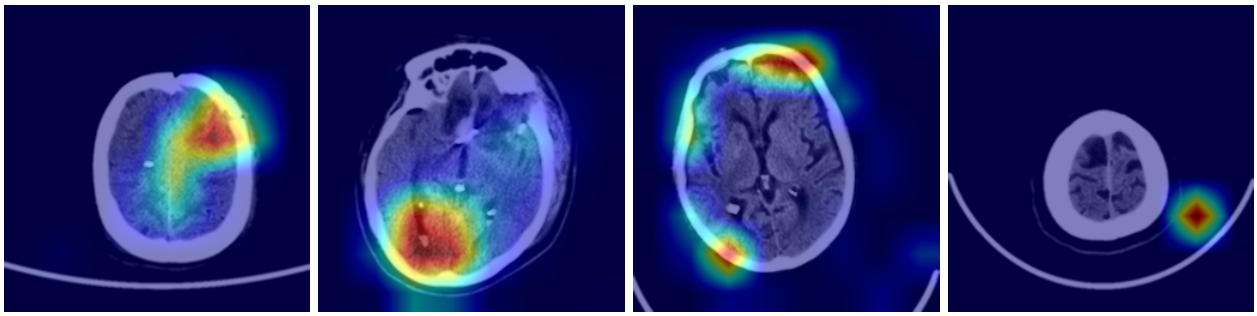

(a) Corect 0 (b) Corect 1 (c) Eroare 0 (d) Eroare 1

Figure 12: Vizualizări Grad-CAM pentru clasa Subdural.

Pentru hemoragiile de tip subdural, se observă că modelul reușește să își concentreze activarea în proximitatea marginilor creierului, fiind mai aproape de locația anatomică reală a acestui tip de sângerare. Deși persistă tendința de a include elemente din *background* în procesul de decizie, faptul că heatmap-urile urmăresc marginile creierului sugerează că modelul a identificat corect zona de risc pentru această clasă, chiar dacă precizia localizării nu este perfectă.

6.5 Analiza Clasei: Subarachnoid

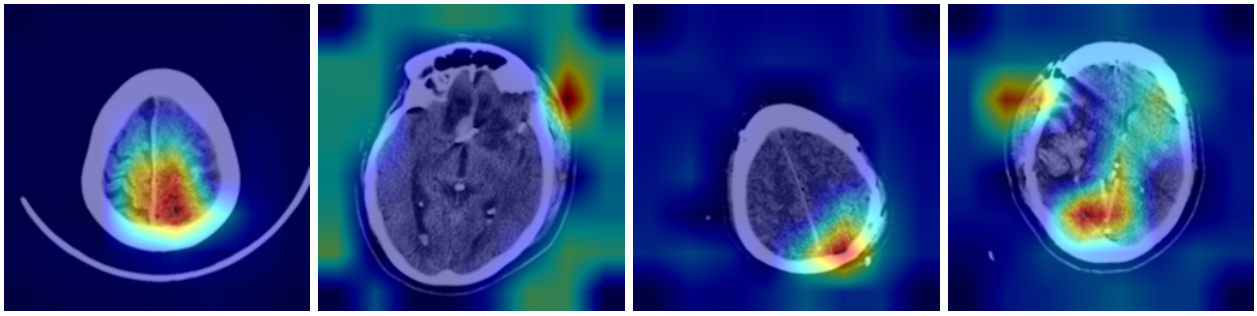

(a) Corect 0 (b) Corect 1 (c) Eroare 0 (d) Eroare 1

Figure 13: Vizualizări Grad-CAM pentru clasa Subarachnoid.

În cazul hemoragiilor subarahnoidiene, modelul prezintă rezultate mixte. S-au identificat predicții corecte în care hărțile de activare sunt localizate corespunzător, însă persistă cazurile în care decizia este bazată pe elemente de *background*, indicând o "ghicire" a diagnosticului. Totodată, din cauza naturii difuze a acestui tip de sângerare, modelul face adesea confuzii cu alte tipuri de hemoragii precum cele epidurale sau subdurale sau poate rata complet identificarea sângerărilor.

6.6 Analiza Clasei: Any

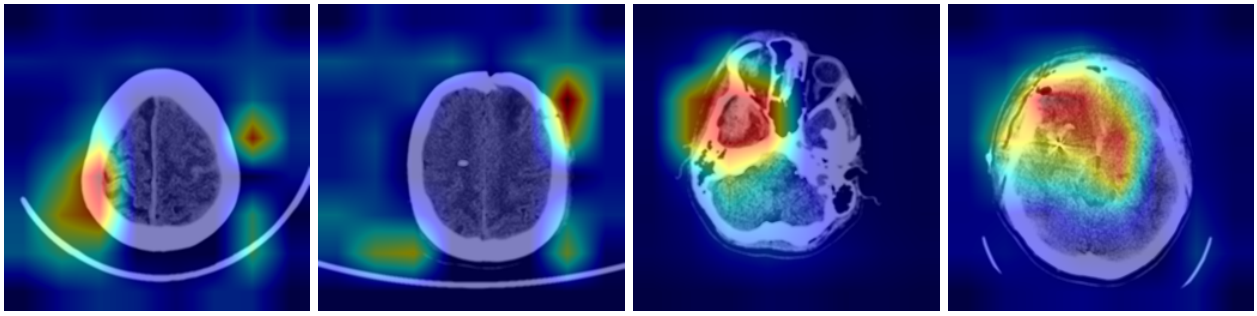

(a) Corect 0 (b) Corect 1 (c) Eroare 0 (d) Eroare 1

Figure 14: Vizualizări Grad-CAM pentru clasa Any.

Multe predicții corecte sunt bazate pe activări în *background*, sugerând că modelul detectează prezența unei hemoragii prin indicii indirecte, nu prin identificarea directă a sângelui. În cazurile eronate, s-a observat că modelul focalizează uneori **exact** pe zona hemoragiei, dar decide eronat că imaginea este sănătoasă (sub pragul de probabilitate). Acest lucru indică faptul că, deși rețeaua extrage trăsăturile vizuale corecte, interpretarea finală a acestora este inconsistentă.

7 Bonus 2

În cadrul acestei cerințe, am utilizat modelul preantrenat **EfficientNet-B0**.

7.1 Rezultate

Experimentele au fost realizate pe Fold-ul 2 pentru consistență cu studiul de ablație.

Configurație	Accuracy	AUC	Precision	Recall	F1	Hamming
Backbone Frozen	20.96%	0.7377	0.5244	0.6214	0.5382	0.5408
Backbone Unfrozen	**45.05%**	**0.9115**	**0.6922**	**0.7842**	**0.7034**	**0.7196**

Table 8: Comparație Backbone Frozen vs. Unfrozen

7.2 Concluzii

1. **Scăderea metricilor**
   Toate metricele au scăzut semnificativ (Acuratețea a căzut de la 45% la 20%, iar AUC de la 0.91 la 0.73). Acest lucru se întâmplă deoarece restul rețelei rămâne blocat pe caracteristici învățate din imagini cu obiecte și animale (ImageNet), care nu au nicio legătură cu imaginile medicale din setul nostru de date.

2. **Concluzie**
   Experimentul arată că fine-tuning-ul este obligatoriu. Modelul are nevoie să-și modifice toți parametrii pentru a înțelege diferența dintre un țesut sănătos și o hemoragie, simpla schimbare a ultimului strat nefiind suficientă pentru un diagnostic corect.